

МИНИСТЕРСТВО ОБРАЗОВАНИЯ И НАУКИ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ПРОФЕССИОНАЛЬНОГО ОБРАЗОВАНИЯ
Национальный исследовательский ядерный университет «МИФИ»



Институт интеллектуальных кибернетических систем

КАФЕДРА КИБЕРНЕТИКИ

БДЗ

по курсу "Математическая статистика"

студента группы Б23-504

Бученкова Владислава Максимовича

Вариант № 1

Оценка: _____

Подпись: _____

2025 г.

ОТЧЕТ № 1

по теме «Проверка статистических гипотез»

Вариант №1

ФИО студента Бученков Владислав Максимович группа Б23-504

Оценка: _____ Подпись: _____

Результаты статистических тестов:

№ задания	Проверяемая гипотеза H_0	Критерий	Статистическое решение ($\alpha = 0.1$)	Вывод
4.1	$X \sim N$	Хи-квадрат	H_0 отклоняется	$X \sim N$
4.2	$X \sim N$	Харке-Бера	H_0 отклоняется	$X \sim N$
5.1	$F_X(x) = F_Y(x)$	знаков	H_0 отклоняется	$F_X(x) \neq F_Y(x)$
5.2	$F_X(x) = F_Y(x)$	Хи-квадрат	H_0 отклоняется	$F_X(x) \neq F_Y(x)$

Выводы:

В результате проведённого в п.4 статистического анализа обнаружено, что критерий χ^2 отвергает гипотезу о нормальности распределения, как и критерий Харке-Бера отвергает её. Из этого можно сделать вывод, что выборка А5 не имеет нормального распределения.

В результате проведённого в п.5 статистического анализа обнаружено, что выборки А5 и А6 неоднородны

ОТЧЕТ № 2

по теме «Анализ статистических взаимосвязей»

Вариант №1

ФИО студента Бученков Владислав Максимович группа Б23-504

Оценка: _____ Подпись: _____

Результаты статистических тестов:

№ задания	Проверяемая гипотеза H_0	Критерий	Статистическое решение ($\alpha = 0.1$)	Вывод
6	$F_Y(y _{X=x^{(1)}}) = F_Y(y _{X=x^{(2)}}) = \dots = F_Y(y _{X=x^{(k_1)}}) = F_Y(y)$	Хи-квадрат	H_0 отклоняется	$\exists i, j : F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$
7	$F_Y(y _{X=x^{(1)}}) = F_Y(y _{X=x^{(2)}}) = \dots = F_Y(y _{X=x^{(k_1)}}) = F_Y(y)$	ANOVA	H_0 отклоняется	$\exists i, j : F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$

Выводы:

В результате проведённого в п.6 статистического анализа обнаружено, что между факторным признаком А4 и результативным признаком А9 присутствует статистическая связь, признак А4 оказывает влияние на распределение признака А9

В результате проведённого в п.7 статистического анализа обнаружено, что между факторным признаком А4 и результативным признаком А5 присутствует статистическая связь, признак А4 оказывает влияние на распределение признака А5.

ОТЧЕТ № 3

по теме «Основы регрессионного анализа»

Вариант №1

ФИО студента Бученков Владислав Максимович группа Б23-504

Оценка: _____ Подпись: _____

Сводная таблица свойств различных регрессионных моделей:

Свойство	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
Точность	Точная	Точная	Точная
Значимость	Значимая	Значимая	Значимая

Адекватность	Адекватная	Адекватная	Адекватная
Степень тесноты связи	Умеренная	Заметная	Очень тесная

Выводы:

В результате проведенного в п.8 статистического анализа обнаружено, что между признаками A5 и A6 существует очень сильная положительная корреляционная связь, преимущественно линейная. Также между признаками A5, A6 и A7 наблюдается положительная монотонная корреляционная связь (по Кендаллу). Наиболее сильная монотонная связь наблюдается между A5 и A6, наименее сильная - между A5 и A7.

В результате проведенного в п.9 статистического анализа обнаружено, что результативный признак A10 имеет умеренную связь с факторным признаком A15 в простейшей линейной модели. При учёте нелинейности теснота связи возрастает до заметной. При добавлении в модель второго факторного признака A5 связь между результативным признаком A10 и факторными признаками становится очень тесной (почти функциональной), то есть большая часть вариации у объясняется совместным влиянием A15 и

1. Описательные статистики

1.1. Выборочные характеристики

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Анализируемый признак 3 – А7

а) Привести формулы расчёта выборочных характеристик

Выборочная хар-ка	Формула расчета
Объём выборки	n
Среднее	$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{n}(x_1 + \dots + x_n)$
Выборочная дисперсия	$s^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
Выборочное среднеквадратическое отклонение	$s = \sqrt{\left(\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right)}$
Выборочный коэффициент асимметрии	$\gamma_x = \left[\frac{n}{(n-1)(n-2)} \right] \frac{\sum_{i=1}^n (X_i - \bar{X})^3}{s^3}$
Выборочный эксцесс	$\epsilon_x = \frac{n(n+1)}{(n-1)(n-2)(n-3)} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{s} \right)^4 - \frac{3(n-1)^2}{(n-2)(n-3)}$

б) Рассчитать выборочные характеристики

Выборочная хар-ка	Признак 1	Признак 2	Признак 3
Среднее	526.48	420.04	355.09
Выборочная дисперсия	13868.86	4953.14	2901.58
Выборочное среднеквадратическое отклонение	117.77	70.38	53.87
Выборочный коэффициент асимметрии	0.68	0.35	0.45

Выборочный эксцесс	0.53	0.18	0.43
--------------------	------	------	------

1.2. Группировка и гистограммы частот

Анализируемый признак – А5

Объём выборки – 1073

а) Выбрать число групп


Число групп	Обоснование выбора числа групп	Ширина интервалов
11	Формула Стерджесса: $k = 1 + 3.322 \lg(n) \sim 11$	От 67.18 до 67.92

б) Построить таблицу частот


Номер интервала	Нижняя граница	Верхняя граница	Частота	Относит. частота	Накопл. частота	Относит. накопл. частота
1	269,26	337,18	28	0,03	28	0,03
2	337,18	404,36	118	0,11	146	0,14
3	404,36	471,55	227	0,21	373	0,35
4	471,55	538,73	277	0,26	650	0,61
5	538,73	605,91	171	0,16	821	0,77
6	605,91	673,09	123	0,11	944	0,88
7	673,09	740,27	80	0,07	1024	0,95
8	740,27	807,46	31	0,03	1055	0,98
9	807,46	874,64	7	0,01	1062	0,99
10	874,64	941,82	7	0,01	1069	1,0
11	941,82	1009,0	4	0,00	1073	1,0

в) Построить гистограммы частот и полигоны частот


Гистограмма и полигон частот




Гистограмма и полигон относительных частот



Гистограмма и полигон накопленных частот




Гистограмма и полигон накопленных относительных частот



г) Построить график эмпирической функции распределения

Эмпирическая функция распределения



2. Интервальные оценки

2.1. Доверительные интервалы для мат. ожидания

Анализируемый признак – А5

Объём выборки – 1073

Оцениваемый параметр – m

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\bar{x} - t_{\frac{\alpha}{2}, n-1} \cdot \frac{s}{\sqrt{n}}$
Верхняя граница	$\bar{x} + t_{1-\frac{\alpha}{2}, n-1} \cdot \frac{s}{\sqrt{n}}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	517.21	519.43	520.57
Верхняя граница	535.76	533.54	532.4

2.2. Доверительные интервалы для дисперсии

Анализируемый признак – А5

Объём выборки – 1073

Оцениваемый параметр – σ^2

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\frac{(n-1) \cdot s^2}{\chi^2_{1-\frac{\alpha}{2}, n-1}}$

Верхняя граница	$\frac{(n-1) \cdot s^2}{\chi^2_{\frac{\alpha}{2}, n-1}}$
-----------------	--

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	12441.11	12765.76	12936.26
Верхняя граница	15543.74	15122.13	14912.28

2.3. Доверительные интервалы для разности мат. ожиданий

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073

Оцениваемый параметр – $m_1 - m_2$

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$(\bar{x}_1 - \bar{x}_2) - t_{1-\frac{\alpha}{2}, n_1+n_2-2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$
Верхняя граница	$(\bar{x}_1 - \bar{x}_2) + t_{1-\frac{\alpha}{2}, n_1+n_2-2} \sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	95.64	98.23	99.55
Верхняя граница	117.24	114.66	113.33

2.4. Доверительные интервалы для отношения дисперсий

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073

Оцениваемый параметр – σ_1^2/σ_2^2

а) Привести формулы расчёта доверительных интервалов

Граница доверительного интервала	Формула расчета
Нижняя граница	$\frac{s_1^2}{s_2^2} \cdot F_{\frac{\alpha}{2}, (n_2-1, n_1-1)}$
Верхняя граница	$\frac{s_1^2}{s_2^2} \cdot F_{1-\frac{\alpha}{2}, (n_2-1, n_1-1)}$

б) Рассчитать доверительные интервалы

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	2.39	2.48	2.53
Верхняя граница	3.27	3.15	3.09

3. Проверка статистических гипотез о математических ожиданиях и дисперсиях

3.1. Проверка статистических гипотез о математических ожиданиях

Анализируемый признак – А5

Объём выборки – 1037

Статистическая гипотеза – $H_0 : m = m_0$; $H' : m \neq m_0$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{\bar{X} - m_0}{S/\sqrt{n}}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$T(n - 1)$
Формулы расчета критических точек	$\pm t_{1-\frac{\alpha}{2}, n-1}$
Формула расчета p -value	$2 \min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Выбрать произвольные значения m_0 и проверить статистические гипотезы

m_0	Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
120	0.1	113.06	0.00	H_0 отклоняется	$m \neq 120$
180	0.1	96.37	0.00	H_0 отклоняется	$m \neq 180$
240	0.1	79.69	0.00	H_0 отклоняется	$m \neq 240$

3.2. Проверка статистических гипотез о дисперсиях

Анализируемый признак – А5

Объём выборки – 1073

Статистическая гипотеза – $H_0 : \sigma = \sigma_0$; $H' : \sigma \neq \sigma_0$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{(n - 1)S^2}{\sigma_0^2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(n - 1)$
Формулы расчета критических точек	$\chi_{\frac{\alpha}{2}, n-1}^2, \chi_{1-\frac{\alpha}{2}, n-1}^2$
Формула расчета p -value	$2 \min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Выбрать произвольные значения σ_0 и проверить статистические гипотезы

σ_0	Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
10	0.1	148674.14	0.00	H_0 отклоняется	$\sigma \neq 10$
20	0.1	37168.53	0.00	H_0 отклоняется	$\sigma \neq 20$
30	0.1	16519.35	0.00	H_0 отклоняется	$\sigma \neq 30$

3.3. Проверка статистических гипотез о равенстве математических ожиданий

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073 1073

Статистическая гипотеза – $H_0 : m_1 = m_2$; $H' : m_1 \neq m_2$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{\bar{X}_1 - \bar{X}_2}{S \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}}, S^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$T(n_1 + n_2 - 2)$
Формулы расчета критических точек	$\pm t_{1-\frac{\alpha}{2}, n_1+n_2-2}$
Формула расчета p -value	$2 \min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	25.41	0.00	H_0 отклоняется	$m_1 \neq m_2$
0.05			H_0 отклоняется	$m_1 \neq m_2$
0.1			H_0 отклоняется	$m_1 \neq m_2$

3.4. Проверка статистических гипотез о равенстве дисперсий

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073 1073

Статистическая гипотеза – $H_0 : \sigma_1 = \sigma_2$; $H' : \sigma_1 \neq \sigma_2$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение
Формула расчета статистики критерия	$Z = \frac{S_1^2}{S_2^2}$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(n_1 - 1, n_2 - 1)$
Формулы расчета критических точек	$F_{\frac{\alpha}{2}, n_1-1, n_2-1}, F_{1-\frac{\alpha}{2}, n_1-1, n_2-1}$
Формула расчета p -value	$2 \min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	2.80	0.00	H_0 отклоняется	$\sigma_1 \neq \sigma_2$
0.05			H_0 отклоняется	$\sigma_1 \neq \sigma_2$
0.1			H_0 отклоняется	$\sigma_1 \neq \sigma_2$

4. Критерии согласия

Анализируемый признак – А5

Объём выборки – 1073

4.1. Критерий хи-квадрат

Теоретическое распределение – нормальное.

Статистическая гипотеза – $H_0 : X \sim N$; $H' : X \not\sim N$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \sum_{i=1}^k \frac{(n_i - n \cdot p_i)^2}{n \cdot p_i}$	к - число интервалов в группированном статистическом ряду, n_i - частота попадания случайной величины X в интервал Δ_i p_i - вероятность попадания случайной величины X в интервал Δ_i в условиях H_0 то есть, если $\Delta_i = (a_{i-1}, a_i]$, то $p_i = \int_{a_{i-1}}^{a_i} g(x)dx = G(a_i) - G(a_{i-1})$.
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(k - r - 1)$	г - количество оцениваемых параметров у предполагаемого распределения G
Формула расчета критической точки	$\chi^2_{1-\alpha, k-r-1}$	Малые значения Z нам также подходят, поэтому критическая область выбирается правосторонней
Формула расчета <i>p-value</i>	$1 - F_Z(z_{\text{выб}} H_0)$	


б) Выбрать число групп

Число групп	Обоснование выбора числа групп	Ширина интервалов
11	$k = 1 + 3.322 \lg(n)$ - формула Стерджесса $n \cdot p_i \gtrsim 5$ - поправка на чувствительность	от 33,42 до ∞

в) Построить таблицу частот

Номер интервала	Нижняя граница	Верхняя граница	Частота	Относит. частота	Вероятность попадания в интервал при условии истинности основной гипотезы
1	-inf	337,18	28,00	0,03	0,05
2	337,18	404,36	118,00	0,11	0,10
3	404,36	471,55	227,00	0,21	0,17
4	471,55	505,21	153,00	0,14	0,11
5	505,21	538,73	124,00	0,12	0,11
6	538,73	572,15	91,00	0,08	0,11
7	572,15	605,91	80,00	0,07	0,10
8	605,91	673,09	123,00	0,11	0,14
9	673,09	740,27	80,00	0,07	0,07
10	740,27	807,45	31,00	0,03	0,03
11	807,45	inf	18,00	0,02	0,01

г) Построить гистограмму относительных частот и функцию плотности теоретического распределения на одном графике



д) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	63.40	0.00	H_0 отклоняется	$X \sim N$
0.05	63.40	0.00	H_0 отклоняется	$X \sim N$
0.1	63.40	0.00	H_0 отклоняется	$X \sim N$

4.2. Проверка гипотезы о нормальности на основе коэффициента асимметрии и эксцесса (критерий Харке-Бера)

Статистическая гипотеза – $H_0 : X \sim N$; $H' : X \not\sim N$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = Z_1^2 + Z_2^2$ $Z_1 = \frac{\gamma_X^*}{\sqrt{\frac{6}{n}}}; Z_2 = \frac{\epsilon_X^*}{\sqrt{\frac{24}{n}}}$	γ_X^* - выборочный коэффициент асимметрии ϵ_X^* - выборочный эксцесс, n - объём выборки.

Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(2)$	
Формула расчета критической точки	$\chi^2_{1-\alpha, 2}$	Правосторонняя критическая область.
Формула расчета <i>p-value</i>	$1 - F_Z(z_{\text{выб}} H_0)$	

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	<i>p-value</i>	Статистическое решение	Вывод
0.01	67.96	0.00	H_0 отклоняется	$X \approx N$
0.05			H_0 отклоняется	$X \approx N$
0.1			H_0 отклоняется	$X \approx N$

Вывод (в терминах предметной области)

В результате проведенного в п.4 статистического анализа обнаружено, что критерий χ^2 отвергает гипотезу о нормальности распределения, как и критерий Харке-Бера отвергает её. Из этого можно сделать вывод, что выборка А5 не имеет нормального распределения.

5. Проверка однородности выборок

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073 1073

5.1 Критерий знаков

Статистическая гипотеза – $H_0 : F_X(x) = F_Y(x)$; $H' : F_X(x) \neq F_Y(x)$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{K_+ - \frac{n}{2}}{\sqrt{\frac{n}{4}}}$	K_+ - количество знаков '+' в выборке $z_1, \dots, z_n = x_1 - y_1, \dots, x_n - y_n$
Закон распределения статистики критерия при условии истинности основной гипотезы	$N(0,1)$	
Формула расчета критической точки	$\pm u_{1-\frac{\alpha}{2}}$	Двусторонняя критическая область
Формула расчета p -value	$2 \min(F_Z(z_{\text{выб}} H_0), 1 - F_Z(z_{\text{выб}} H_0))$	

б) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	32.39	0.00	H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.05			H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.1			H_0 отклоняется	$F_X(x) \neq F_Y(x)$

5.2. Критерий хи-квадрат

Статистическая гипотеза – $H_0 : F_X(x) = F_Y(x)$; $H' : F_X(x) \neq F_Y(x)$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = nm \sum_{i=1}^k \frac{1}{n_i + m_i} \left(\frac{n_i}{n} + \frac{m_i}{m} \right)$	k - число интервалов в группированном статистическом ряду. n_i - частота попадания случайной величины X в интервал Δ_i . m_i - частота попадания случайной величины X в интервал Δ_i . n - объём выборки \$ $x_1, \dots, x_n$ m - объём выборки $y_1, \dots, y_m$
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(k - 1)$	
Формула расчета критической точки	$\chi^2_{1-\alpha, k-1}$	Правосторонняя критическая область.
Формула расчета <i>p-value</i>	$1 - F_Z(z_{\text{выб}} H_0)$	


б) Выбрать число групп

Число групп	Обоснование выбора числа групп	Ширина интервалов
11	$k = 1 + 3.322 \lg(n)$ - формула Стерджесса $n_i + m_i \gtrsim 5$ - поправка на чувствительность	от 35.23 до 140.91

в) Построить таблицу частот

Номер интервала	Нижняя граница	Верхняя граница	Частота признака 1	Частота признака 2	Относит. частота признака 1	Относит. частота признака 2
1	234,00	304,45	6,00	41,00	0,01	0,04
2	304,45	374,91	79,00	246,00	0,07	0,23
3	374,91	410,14	78,00	215,00	0,07	0,20
4	410,14	445,36	114,00	227,00	0,11	0,21
5	445,36	515,82	286,00	229,00	0,27	0,21
6	515,82	586,27	203,00	103,00	0,19	0,10
7	586,27	656,73	146,00	10,00	0,14	0,01
8	656,73	727,18	99,00	1,00	0,09	0,00
9	727,18	797,64	40,00	1,00	0,04	0,00
10	797,64	868,09	11,00	0,00	0,01	0,00
11	868,09	1009,00	11,00	0,00	0,01	0,00

г) Построить гистограммы относительных частот на одном графике



д) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	526.07	0.00	H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.05			H_0 отклоняется	$F_X(x) \neq F_Y(x)$
0.1			H_0 отклоняется	$F_X(x) \neq F_Y(x)$

Вывод (в терминах предметной области)

В результате проведённого в п.5 статистического анализа обнаружено, что выборки А5 и А6 неоднородны

6. Таблицы сопряжённости

Факторный признак x – А4

Результативный признак y – А9

Объёмы выборок – 1073 1073

Статистическая гипотеза –

$$H_0 : F_Y(y |_{X=x^{(1)}}) = F_Y(y |_{X=x^{(2)}}) = \dots = F_Y(y |_{X=x^{(k_1)}}) = F_Y(y); \quad H' : \exists i, j : F_Y(y |_{X=x^{(i)}}) \neq F_Y(y |_{X=x^{(j)}})$$

а) Указать формулы расчёта показателей, используемых при проверке статистических гипотез

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \sum_{i=1}^{k_1} \sum_{j=1}^{k_2} \frac{(n_{ij} - m_{ij})^2}{m_{ij}}$	$(x_1, y_1), \dots, (x_n, y_n)$ - наблюдения случайного вектора (X, Y) , где X, Y - случайные величины дискретного типа $x^{(1)}, \dots, x^{(k_1)}$ - варианты признака X $y^{(1)}, \dots, y^{(k_2)}$ - варианты признака Y n_{ij} - выборочная частота варианта $(x^{(i)}, y^{(j)})$ в выборке $(x_1, y_1), \dots, (x_n, y_n)$ m_{ij} - теоретическая частота варианта $(x^{(i)}, y^{(j)})$ в выборке $(x_1, y_1), \dots, (x_n, y_n)$ при условии истинности
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2((k_1 - 1)(k_2 - 1))$	
Формула расчета критической точки	$\chi^2_{1-\alpha, (k_1-1)(k_2-1)}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

б) Построить эмпирическую таблицу сопряжённости

x	y	$y^{(1)}$	$y^{(2)}$	Σ
$x^{(1)}$		13	167	180
$x^{(2)}$		177	182	359
$x^{(3)}$		411	123	534
Σ		601	472	1073

в) Построить теоретическую таблицу сопряжённости

x	y	$y^{(1)}$	$y^{(2)}$	Σ
$x^{(1)}$		100.82	79.18	180.0
$x^{(2)}$		201.08	157.92	359.0
$x^{(3)}$		299.1	234.9	534.0
Σ		601.0	472.0	1073.0

г) Проверить статистические гипотезы

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	275.63	0.00	H_0 отклоняется	$\exists i, j : F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$
0.05			H_0 отклоняется	$\exists i, j : F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$
0.1			H_0 отклоняется	$\exists i, j : F_Y(y _{X=x^{(i)}}) \neq F_Y(y _{X=x^{(j)}})$

Вывод (в терминах предметной области)

В результате проведённого в п.6 статистического анализа обнаружено, что между факторным признаком А4 и результативным признаком А9 присутствует статистическая связь, признак А4 оказывает влияние на распределение признака А9

7. Дисперсионный анализ

Факторный признак x – А4

Результативный признак y – А5

Число вариантов факторного признака – 3

Объёмы выборок – 1073 1073

Статистическая гипотеза –

$$H_0: F_Y(y |_{X=x_1}) = F_Y(y |_{X=x_2}) = \dots = F_Y(y |_{X=x_k}) = F_Y(y)$$

$$H': \exists i, j: F_Y(y |_{X=x_i}) \neq F_Y(y |_{X=x_j})$$

а) Рассчитать групповые выборочные характеристики

№ п/п	Вариант факторного признака	Объём выборки	Групповые средние	Групповые дисперсии
1	I	180	668.53	11290.94
2	IIA	359	542.57	6914.78
3	IIIB	534	467.79	8966.76

б) Привести формулы расчёта показателей вариации, используемых в дисперсионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\widetilde{D}_{\text{межгр}} = \frac{1}{n} \sum_{i=1}^k n_i (\bar{y}_i - \bar{y})^2$	$k - 1$	$\frac{n}{k - 1} \widetilde{D}_{\text{межгр}}$
Остаточные признаки	$\widetilde{D}_{\text{внутр}} = \frac{1}{n} \sum_{i=1}^k n_i \sigma_i^2$, где $\sigma_i^2 = \frac{1}{n_i} \sum_{j=1}^{n_i} (y_{ij} - \bar{y}_i)^2$ — групповая дисперсия	$n - k$	$\frac{n}{k - 1} \widetilde{D}_{\text{межгр}}$
Все признаки	$\widetilde{D}_{\text{общ}} = \frac{1}{n} \sum_{i=1}^k \sum_{j=1}^{n_i} (y_{ij} - \bar{y})^2$	$n - 1$	$\frac{n}{n - 1} \widetilde{D}_{\text{общ}}$

в) Рассчитать показатели вариации, используемые в дисперсионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\widetilde{D}_{\text{межгр}} = 5185.82$	$k - 1 = 2$	$\frac{n}{k - 1} \widetilde{D}_{\text{межгр}} = 2782194.04$
Остаточные признаки	$\widetilde{D}_{\text{внутр}} = 8670.11$	$n - k = 1070$	$\frac{n}{n - k} \widetilde{D}_{\text{внутр}} = 8694.42$
Все признаки	$\widetilde{D}_{\text{общ}} = 13868.86$	$n - 1 = 1072$	$\frac{n}{n - 1} \widetilde{D}_{\text{общ}} = 13868.86$

г) Проверить правило сложения дисперсий

Показатель	$D_{\text{межгр}}$	$D_{\text{внутригр}}$	$D_{\text{общ}}$	$D_{\text{межгр}} + D_{\text{внутригр}}$
Значение	5158.82	8670.11	13855.93	13855.93

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Эмпирический коэффициент детерминации	$\eta^2 = \frac{\widetilde{D}_{\text{межгр}}}{\widetilde{D}_{\text{общ}}}$	0.37
Эмпирическое корреляционное отношение	$\widetilde{\eta} = \sqrt{\eta^2} = \sqrt{\frac{\widetilde{D}_{\text{межгр}}}{\widetilde{D}_{\text{общ}}}}$	0.61

е) Охарактеризовать тип связи между факторным и результативным признаками

По шкале Чеддока наблюдается сильная степень статистической связи между факторным признаком А4 и результативным признаком А5.

ж) Указать формулы расчёта показателей, используемых при проверке статистической гипотезы дисперсионного анализа

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{n - k}{k - 1} \frac{\widetilde{D}_{\text{межгр}}}{\widetilde{D}_{\text{внутр}}}$	k — число групп n — объём выборки $y_1, \dots, y_n$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(k - 1, n - k)$	
Формула расчета критической точки	$F_{1-\alpha, k-1, n-k}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

з) Проверить статистическую гипотезу дисперсионного анализа

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	320.00	0.00	H_0 отклоняется	$F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$
0.05			H_0 отклоняется	$F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$
0.1			H_0 отклоняется	$F_Y(y _{X=x_i}) \neq F_Y(y _{X=x_j})$

Вывод (в терминах предметной области)

В результате проведённого в п.7 статистического анализа обнаружено, что между факторным признаком А4 и результативным признаком А5 присутствует статистическая связь, признак А4 оказывает влияние на распределение признака А5.

8. Корреляционный анализ

8.1. Расчёт парных коэффициентов корреляции

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Объёмы выборок – 1073 1073

а) Рассчитать точечные оценки коэффициентов корреляции

	Формула расчёта	Значение
Линейный коэффициент корреляции	$\tilde{\rho}_{XY} = \frac{\widetilde{cov(X, Y)}}{\tilde{\sigma}_X \cdot \tilde{\sigma}_Y} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \cdot \sum_{i=1}^n (y_i - \bar{y})^2}}$	0.94
Ранговый коэффициент корреляции по Спирмену	$\tilde{\rho}_{XY}^{(sp)} = \tilde{\rho}_{RS}, \text{ где } R \text{ и } S \text{ — ранги для выборок } X \text{ и } Y \text{ соответственно.}$ Можно показать, что $\tilde{\rho}_{XY}^{(sp)} = 1 - \frac{6S}{n(n^2 - 1)}$, где $S = \sum_{i=1}^n (r_i - s_i)^2$	0.95
Ранговый коэффициент корреляции по Кендаллу	$\tilde{\tau}_{XY} = \frac{N_+ - N_-}{n(n-1)/2}, \text{ где}$ N_+, N_- — количество пар точек (x_i, y_i) таких, что $(x_i - x_j)(y_i - y_j) > 0, (x_i - x_j)(y_i - y_j) < 0$ соответственно. Другой вариант расчёта: $\tilde{\tau}_{XY} = \frac{4R}{n(n-1)} - 1, \text{ где}$ $R = \sum_{i=1}^n \sum_{j=i+1}^n 1[s_j > s_i] \text{ — число инверсий в}$ выборке $(r_1, s_1), \dots, (r_n, s_n)$, предварительно отсортированной по возрастанию r_i.	0.82

б) Привести формулы расчёта доверительного интервала для линейного коэффициента корреляции

Для больших объёмов выборок: $n > 500$

Граница доверительного интервала	Формула расчета
Нижняя граница	$\rho_{XY}^* + \frac{\rho_{XY}^*(1 - (\rho_{XY}^*)^2)}{2n} - u_{1-\frac{\alpha}{2}} \frac{1 - (\rho_{XY}^*)^2}{\sqrt{n}}$
Верхняя граница	$\rho_{XY}^* + \frac{\rho_{XY}^*(1 - (\rho_{XY}^*)^2)}{2n} + u_{1-\frac{\alpha}{2}} \frac{1 - (\rho_{XY}^*)^2}{\sqrt{n}}$

в) Рассчитать доверительные интервалы для линейного коэффициента корреляции

Граница доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
Нижняя граница	0.93	0.94	0.94
Верхняя граница	0.95	0.95	0.95

г) Указать формулы расчёта показателей, используемых при проверке значимости коэффициентов корреляции

Статистическая гипотеза	Формула расчета статистики критерия	Закон распределения статистики критерия при условии истинности основной
$H_0: \rho = 0$ $H': \rho \neq 0$	$Z = \frac{\tilde{\rho}_{XY} \cdot \sqrt{n-2}}{\sqrt{1 - \tilde{\rho}_{XY}^2}}$	$T(n-2)$
$H_0: r^{(cn)} = 0$ $H': r^{(cn)} \neq 0$	$Z = \frac{\tilde{\rho}_{XY}^{(sp)} \cdot \sqrt{n-2}}{\sqrt{1 - \left(\tilde{\rho}_{XY}^{(sp)}\right)^2}}$	$T(n-2)$
$H_0: r^{(кен)} = 0$ $H': r^{(кен)} \neq 0$	$\sqrt{\frac{9n(n+1)}{2(2n+5)}} \cdot \tilde{\tau}_{XY}$	$N(0,1)$

д) Проверить значимость коэффициентов корреляции

Статистическая гипотеза	Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
$H_0: \rho = 0$ $H': \rho \neq 0$	0.1	92.48	0.00	H_0 отклоняется	$\rho_{XY} \neq 0$
$H_0: r^{(cn)} = 0$ $H': r^{(cn)} \neq 0$	0.1	102.87	0.00	H_0 отклоняется	$\rho_{XY}^{(sp)} \neq 0$
$H_0: r^{(кен)} = 0$ $H': r^{(кен)} \neq 0$	0.1	40.30	0.00	H_0 отклоняется	$\tau_{XY} \neq 0$

8.2. Расчёт множественных коэффициентов корреляции

Анализируемый признак 1 – А5

Анализируемый признак 2 – А6

Анализируемый признак 3 – А7

Объёмы выборок – 1073

а) Рассчитать матрицу ранговых коэффициентов корреляции по Кендаллу

Признак	Признак	А5	А6	А7
А5		1.0	0.82	0.77
А6		0.82	1.0	0.8
А7		0.77	0.8	1.0

б) Рассчитать матрицу значений p -value для ранговых коэффициентов корреляции по Кендаллу (статистическая гипотеза $H_0: r^{(кен)} = 0$, $H': r^{(кен)} \neq 0$)

Признак	Признак	А5	А6	А7
А5		–	0.0	0.0
А6		0.0	–	0.0
А7		0.0	0.0	–

в) Рассчитать точечную оценку коэффициента конкордации

	Формула расчета	Значение
Коэффициент конкордации	$\widetilde{W} = \frac{12}{k^2(n^3 - n)} \cdot \sum_{i=1}^n \left(\sum_{j=1}^k r_{ij} - \frac{k(n+1)}{2} \right)^2$, где r_{ij} — ранг i-ого объекта в j-ой выборке. k — количество выборок. n — объём выборок.	0.96

г) Указать формулы расчёта показателей, используемых при проверке значимости коэффициента конкордации

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = n(k - 1) \widetilde{W}$	$\widetilde{W}$ — точечная оценка коэффициента конкордации. k — количество выборок. n — объём каждой выборки.
Закон распределения статистики критерия при условии истинности основной гипотезы	$\chi^2(n - 1)$	
Формула расчета критической точки	$\chi^2_{1-\alpha, n-1}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

д) Проверить значимость коэффициента конкордации

Уровень значимости	Выборочное значение статистики критерия	<i>p-value</i>	Статистическое решение	Вывод
0.01	2060.76	0.00	H_0 отклоняется	$W \neq 0$
0.05			H_0 отклоняется	$W \neq 0$
0.1			H_0 отклоняется	$W \neq 0$

Вывод (в терминах предметной области)

В результате проведённого в п.8 статистического анализа обнаружено, что между признаками A5 и A6 существует очень сильная положительная корреляционная связь, преимущественно линейная. Также между признаками A5, A6 и A7 наблюдается положительная монотонная корреляционная связь (по Кендаллу). Наиболее сильная монотонная связь наблюдается между A5 и A6, наименее сильная — между A5 и A7.

9. Регрессионный анализ

9.1 Простейшая линейная регрессионная модель

Факторный признак x – А15

Результативный признак y – А10

Уравнение регрессии – $f(x) = \beta_0 + \beta_1 x$

9.1.1. Точечные оценки линейной регрессионной модели

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\bar{y} - \rho_{XY} \cdot \frac{\tilde{\sigma}_Y}{\tilde{\sigma}_X} \cdot \bar{x}$	599.27
β_1	$\rho_{XY} \cdot \frac{\tilde{\sigma}_Y}{\tilde{\sigma}_X}$	0.56

б) Записать точечную оценку уравнения регрессии

$f(x) = 599.27 + 0.56 \cdot x$

в) Привести формулы расчёта показателей вариации, используемых в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	$\widetilde{D}_{Y X} = \frac{1}{n} \sum_{i=1}^n (\tilde{f}(x_i) - \bar{y})^2$	$k - 1$	$\frac{n}{k - 1} \widetilde{D}_{Y X}$
Остаточные признаки	$\widetilde{D}_{\text{ост}} = \frac{1}{n} \sum_{i=1}^n (\tilde{f}(x_i) - y_i)^2$	$n - k$	$\frac{n}{n - k} \widetilde{D}_{\text{ост}}$
Все признаки	$\widetilde{D}_{\text{общ}} = \frac{1}{n} \sum_{i=1}^n (y_i - \bar{y})^2$	$n - 1$	$\frac{n}{n - 1} \widetilde{D}_{\text{общ}}$

г) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	6642.54	$k - 1 = 1$	7127440.21
Остаточные признаки	16114.63	$n - k = 1071$	16144.72
Все признаки	22757.17	$n - 1 = 1072$	22778.40

д) Проверить правило сложения дисперсий

Показатель	$D_{\text{регр}}$	$D_{\text{ост}}$	$D_{\text{общ}}$	$D_{\text{регр}} + D_{\text{ост}}$
Значение	6642.54	16114.63	22757.17	22757.17

е) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Коэффициент детерминации	$\widetilde{R^2} = \frac{\widetilde{D_{Y X}}}{\widetilde{D_{Y\text{общ}}}}$	0.29
Корреляционное отношение	$\widetilde{R} = \sqrt{\widetilde{R^2}} = \sqrt{\frac{\widetilde{D_{Y X}}}{\widetilde{D_{Y\text{общ}}}}}$	0.54

ж) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией

Наблюдается умеренная прямая (положительная) корреляционная связь между факторным признаком А15 и результативным признаком А10

9.1.2. Интервальные оценки линейной регрессионной модели

а) Привести формулы расчёта доверительных интервалов для параметров линейной регрессионной модели

Параметр	Границы доверительного интервала	Формула расчета
β_0	Нижняя граница	$\sim \beta_0 - t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{\widetilde{D_{Y_{OCT}}^{\text{несмещ}}}} \cdot \sqrt{\frac{\sum_{i=1}^n x_i^2}{n^2 \widetilde{D_X}}}$
	Верхняя граница	$\sim \beta_0 + t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{\widetilde{D_{Y_{OCT}}^{\text{несмещ}}}} \cdot \sqrt{\frac{\sum_{i=1}^n x_i^2}{n^2 \widetilde{D_X}}}$
β_1	Нижняя граница	$\sim \beta_1 - t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{\widetilde{D_{Y_{OCT}}^{\text{несмещ}}}} \cdot \sqrt{\frac{1}{n \widetilde{D_X}}}$
	Верхняя граница	$\sim \beta_1 + t_{1-\frac{\alpha}{2},(n-2)} \cdot \sqrt{\widetilde{D_{Y_{OCT}}^{\text{несмещ}}}} \cdot \sqrt{\frac{1}{n \widetilde{D_X}}}$

б) Рассчитать доверительные интервалы для параметров линейной регрессионной модели


Параметр	Границы доверительного интервала	$\alpha = 0.01$	$\alpha = 0.05$	$\alpha = 0.1$
β_0	Нижняя граница	587.037015	589.968194	591.465931
	Верхняя граница	611.505243	608.574065	607.076327
β_1	Нижняя граница	0.490327	0.506775	0.515179
	Верхняя граница	0.627625	0.611177	0.602773

в) Привести формулы расчёта доверительного интервала для значений регрессии $f(x)$


Границы доверительного интервала	Формула расчета
----------------------------------	-----------------

Нижняя граница $f_{low}(x)$	$(\tilde{\beta}_0 + \tilde{\beta}_1 x) - t_{1-\frac{\alpha}{2}, (n-2)} \cdot \sqrt{\tilde{D}_{Y_{OCT}}^{\text{несмещ}}} \cdot \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{n \tilde{D}_X}}$
Верхняя граница $f_{high}(x)$	$(\tilde{\beta}_0 + \tilde{\beta}_1 x) + t_{1-\frac{\alpha}{2}, (n-2)} \cdot \sqrt{\tilde{D}_{Y_{OCT}}^{\text{несмещ}}} \cdot \sqrt{\frac{1}{n} + \frac{(x - \bar{x})^2}{n \tilde{D}_X}}$

г) Построить диаграмму рассеяния признаков x и y . Нанести на диаграмму функцию регрессии $f(x)$, а также нижние и верхние границы линии регрессии $f_{low}(x)$ и $f_{high}(x)$ на уровне значимости $\alpha = 0.1$



д) Построить график остатков $\varepsilon(x) = y - f(x)$



9.1.3. Проверка значимости линейной регрессионной модели

$$H_0: \beta_1 = 0$$

Статистическая гипотеза – $H': \beta_1 \neq 0$

а) Указать формулы расчёта показателей, используемых при проверке значимости линейной регрессионной модели

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{\widetilde{D_{Y X}}}{D_{\text{уст}}/(n-2)}$	n — объём выборки $(x_1, y_1), \dots, (x_n, y_n)$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(1, n-2)$	
Формула расчета критической точки	$F_{1-\alpha, 1, n-2}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

б) Проверить значимость линейной регрессионной модели

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	441.47	0.00	H_0 отклоняется	$\beta_1 \neq 0$
0.05			H_0 отклоняется	$\beta_1 \neq 0$
0.1			H_0 отклоняется	$\beta_1 \neq 0$

9.2 Линейная регрессионная модель общего вида

Факторный признак x – A15

Результативный признак y – A10

Уравнение регрессии – квадратичное по x : $f(x) = \beta_0 + \beta_1 x + \beta_2 x^2$

9.2.1. Точечные оценки линейной регрессионной модели

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\tilde{\beta} = (F^T F)^{(-1)} F^T y, \text{ где}$ $\beta = (\beta_0, \dots, \beta_{k-1})^T \text{—вектор параметров модели}$ $y = (y_1, \dots, y_n)^T \text{— вектор откликов модели}$	563.01
β_1		1.26
β_2		0.00

б) Записать точечную оценку уравнения регрессии

$$f(x) = \tilde{\beta}_0 + \tilde{\beta}_1 x + \tilde{\beta}_2 x^2 = 563.01 - 1.26x + 0x^2$$

в) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	8621.25	$k - 1 = 2$	9250606.47
Остаточные признаки	14135.91	$n - k = 1070$	14162.31
Все признаки	22757.17	$n - 1 = 1072$	22778.40

г) Проверить правило сложения дисперсий

Показатель	$D_{\text{регр}}$	$D_{\text{ост}}$	$D_{\text{общ}}$	$D_{\text{регр}} + D_{\text{ост}}$
Значение	8621.25	14135.91	22757.17	22757.17

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Коэффициент детерминации	$\widetilde{R^2} = \frac{\widetilde{D_{Y X}}}{\widetilde{D_{Y\text{общ}}}}$	0.38
Корреляционное отношение	$\widetilde{R} = \sqrt{\widetilde{R^2}} = \sqrt{\frac{\widetilde{D_{Y X}}}{\widetilde{D_{Y\text{общ}}}}}$	0.62

е) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией


Наблюдается достаточно тесная (умеренно сильная) нелинейная корреляционная связь между факторным признаком A15 и результативным признаком A10: корреляционное отношение $R \approx 0.62$ (при $R^2 \approx 0.38$).

9.2.2. Интервальные оценки линейной регрессионной модели


а) Привести формулы расчёта доверительного интервала для значений регрессии $f(x)$

Границы доверительного интервала	Формула расчета
Нижняя граница $f_{low}(x)$	$\sim f(x) - t_{1-\frac{\alpha}{2},(n-k)} \cdot \sqrt{\frac{\sim_{\text{несмещ}}}{D_{Y_{\text{ост}}}}} \cdot \sqrt{\vec{\phi}(x)(F^T F)^{-1} \phi_{\downarrow}(x)}$
Верхняя граница $f_{high}(x)$	$\sim f(x) + t_{1-\frac{\alpha}{2},(n-k)} \cdot \sqrt{\frac{\sim_{\text{несмещ}}}{D_{Y_{\text{ост}}}}} \cdot \sqrt{\vec{\phi}(x)(F^T F)^{-1} \phi_{\downarrow}(x)}$

б) Построить диаграмму рассеяния признаков x и y . Нанести на диаграмму функцию регрессии $f(x)$, а также нижние и верхние границы линии регрессии $f_{low}(x)$ и $f_{high}(x)$ на уровне значимости $\alpha = 0.1$



в) Построить график остатков $\varepsilon(x) = y - f(x)$



9.2.3. Проверка значимости линейной регрессионной модели

$$H_0: \beta_1 = \beta_2 = 0$$

Статистическая гипотеза – $H':$ 0

а) Указать формулы расчёта показателей, используемых при проверке значимости линейной регрессионной модели

	Выражение	Пояснение использованных обозначений
Формула расчета статистики критерия	$Z = \frac{\widetilde{D_{Y X}}_{\text{несмещ}}}{\widetilde{D_{Y\text{ост}}}_{\text{несмещ}}}$	n — объём выборки $(x_1, y_1), \dots, (x_n, y_n)$
Закон распределения статистики критерия при условии истинности основной гипотезы	$F(k - 1, n - 2)$	
Формула расчета критической точки	$F_{1-\alpha, k-1, n-2}$	Правосторонняя критическая область
Формула расчета p -value	$1 - F_Z(z_{\text{выб}} H_0)$	

б) Проверить значимость линейной регрессионной модели

Уровень значимости	Выборочное значение статистики критерия	p -value	Статистическое решение	Вывод
0.01	326.29	0.00	H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$
0.05			H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$
0.1			H_0 отклоняется	$\beta_1^2 + \beta_2^2 > 0$

9.3 Множественная линейная регрессионная модель

Факторный признак 1 x_1 – A15

Факторный признак 2 x_2 – A5

Результативный признак y – A10

Уравнение регрессии – $f(x) = \beta_0 + \beta_1 x_1 + \beta_2 x_2$

а) Рассчитать точечные оценки параметров линейной регрессионной модели

Параметр	Формула расчета	Значение
β_0	$\tilde{\beta} = (F^T F)^{(-1)} F^T y$, где $\beta = (\beta_0, \dots, \beta_{k-1})^T$ — вектор параметров модели $y = (y_1, \dots, y_n)^T$ — вектор откликов модели	-18.84
β_1		-0.03
β_2		1.29

б) Записать точечную оценку уравнения регрессии

$$f(x) = \tilde{f}(x) = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{\beta}_2 x_2 = -18.84 - 0.03x_1 + 1.29x_2$$

в) Рассчитать показатели вариации, используемые в регрессионном анализе

Источник вариации	Показатель вариации	Число степеней свободы	Несмещенная оценка
Факторный признак	8621.25	$k - 1 = 2$	9250606.47
Остаточные признаки	14135.91	$n - k = 1070$	14162.31

Все признаки	22757.17	$n - 1 = 1072$	22778.40
--------------	----------	----------------	----------

г) Проверить правило сложения дисперсий

Показатель	$D_{рег}$	$D_{ост}$	$D_{общ}$	$D_{рег} + D_{ост}$
Значение	8621.25	14135.91	22757.17	22757.17

д) Рассчитать показатели тесноты связи между факторным и результативным признаками

Показатель	Формула расчета	Значение
Множественный коэффициент детерминации	$\widetilde{R^2} = \frac{\widetilde{D_{Y X_1, X_2}}}{\widetilde{D_{Yобщ}}}$	0.98
Множественное корреляционное отношение	$\widetilde{R} = \sqrt{\widetilde{R^2}} = \sqrt{\frac{\widetilde{D_{Y X_1, X_2}}}{\widetilde{D_{Yобщ}}}}$	0.99

е) Охарактеризовать тип связи между факторным и результативным признаками, определяемой рассчитанной линейной регрессией

Тип связи между факторными признаками А15, А5 и результативным признаком А10, определяемой рассчитанной множественной линейной регрессией, - очень сильная (почти функциональная)

9.4. Выводы

а) Сводная таблица показателей вариации для различных регрессионных моделей

Источник вариации	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
Факторный признак	6642.54	8621.25	8621.25
Остаточные признаки	16114.63	14135.91	14135.91
Все признаки	22757.17	22757.17	22757.17

б) Сводная таблица свойств различных регрессионных моделей

Свойство	Простейшая линейная модель	Линейная модель с квадратичным членом	Множественная линейная модель
Точность	Точная	Точная	Точная
Значимость	Значимая	Значимая	Значимая
Адекватность	Адекватная	Адекватная	Адекватная
Степень тесноты связи	Умеренная	Заметная	Очень тесная

Вывод (в терминах предметной области)

В результате проведённого в п.9 статистического анализа обнаружено, что результативный признак А10 имеет умеренную связь с факторным признаком А15 в простейшей линейной модели. При учёте нелинейности теснота связи возрастает до заметной. При добавлении в модель второго факторного признака А5 связь между результативным признаком А10 и факторными признаками становится очень тесной (почти функциональной), то есть большая часть вариации у объясняется совместным влиянием А15 и А5.